

Previsão do preço futuro da ação ITUB4 Utilizando Redes Neurais Recorrentes do Tipo LSTM

Gabriel Alves de F Spinola Sucupira¹, Henrique Pena Ribeiro¹
Lucas Zanini da Silva¹, Tiago Teraoka e Sá¹

¹Faculdade de Computação e Informática – Universidade Presbiteriana Mackenzie

Abstract. *The Brazilian stock exchange (B3) has seen a 23% growth in individual investors in 2023, creating demand for analytical tools to support decision-making. This paper presents the partial results of a project that applies a single-layer Long Short-Term Memory (LSTM) neural network for one-day-ahead closing price prediction of the ITUB4 stock (Itaú Unibanco) on the B3. Historical data from the past 5 years is collected via the yfinance API, covering Open, High, Low, Close, Volume, and a 60-day Exponential Moving Average (EMA-60) as features. Data is standardized with Z-score normalization and structured into 50-day temporal windows with a chronological train/test split (80%/20%). A persistence model is implemented as a baseline. Performance will be evaluated using RMSE, MAE, and MAPE metrics. The expected outcome is a model that consistently outperforms the baseline and serves as the backend for an interactive Streamlit web application.*

Resumo. *A bolsa de valores brasileira (B3) registrou crescimento de 23% no número de investidores pessoas físicas em 2023, ampliando a demanda por ferramentas de apoio à tomada de decisão. Este documento apresenta os resultados parciais de um projeto que aplica uma rede neural recorrente do tipo LSTM (Long Short-Term Memory) de camada única para a previsão do preço de fechamento do ativo ITUB4 (Itaú Unibanco) na B3 com horizonte de um dia. Os dados históricos dos últimos 5 anos são coletados via API yfinance, utilizando abertura, máxima, mínima, fechamento, volume e Média Móvel Exponencial de 60 dias (EMA-60) como variáveis preditoras. Os dados são normalizados via Z-score e organizados em janelas temporais de 50 dias, com divisão cronológica em treino e teste (80%/20%). Um modelo de persistência é implementado como baseline de comparação. A avaliação utilizará as métricas RMSE, MAE e MAPE. Como resultado esperado, o modelo deve superar o baseline e ser integrado em uma aplicação web interativa desenvolvida com Streamlit.*

1. Introdução

1.1. Contextualização

O mercado de capitais brasileiro, operado pela B3 (Brasil, Bolsa e Balcão), tem vivenciado crescimento expressivo na última década. Segundo dados da própria bolsa, o número de investidores pessoas físicas cresceu 23% em 2023, ampliando significativamente a base de participantes do mercado acionário nacional. Esse crescimento, no entanto, não é acompanhado proporcionalmente pela capacitação técnica dos novos investidores, muitos dos quais ingressam sem o embasamento necessário para análise fundamentalista ou técnica dos ativos [Zanotto and Hölbisg 2026].

O comportamento dos preços de ações é determinado por uma complexa combinação de fatores: indicadores técnicos derivados do histórico de preços, variáveis macroeconômicas (taxa de juros, inflação, câmbio), resultados financeiros das empresas e eventos externos de caráter político ou geopolítico. A análise manual e integrada de todos esses fatores ultrapassa a capacidade operacional da maioria dos investidores individuais, criando espaço para soluções baseadas em Inteligência Artificial (IA) que consigam extrair padrões significativos de séries históricas.

1.2. Justificativa

Modelos clássicos de séries temporais, como o ARIMA, assumem linearidade e estacionariedade nos dados, premissas raramente satisfeitas em séries financeiras reais [Box and Jenkins 1970]. Redes neurais recorrentes do tipo LSTM (*Long Short-Term Memory*), propostas por Hochreiter e Schmidhuber (1997), foram projetadas especificamente para aprender dependências temporais de longo prazo em dados sequenciais não-lineares, tornando-as candidatas naturais para a previsão de preços de ativos financeiros [Hochreiter and Schmidhuber 1997].

A revisão sistemática de [Mintarya et al. 2023] confirma que a adoção de LSTM em aplicações financeiras cresceu de forma consistente a partir de 2015, superando abordagens como SVM e redes neurais convencionais. No contexto específico da B3, estudos como os de [Silveira 2021] e [Zanotto and Hölbis 2026] demonstram a viabilidade e a eficácia dessa arquitetura para previsão de ativos brasileiros, área com menor cobertura na literatura do que bolsas internacionais como a NYSE ou a bolsa de Xangai.

1.3. Objetivo

O objetivo geral deste projeto é desenvolver, treinar e validar um modelo LSTM de camada única para prever o preço de fechamento do ativo ITUB4 (Itaú Unibanco S.A.) na B3 com antecedência de um dia útil, utilizando dados históricos de preços e indicadores técnicos derivados. Como objetivos específicos, destacam-se:

- Coletar e preparar uma série histórica de 5 anos do ativo ITUB4 via API *yfinance* (Open, High, Low, Close, Volume);
- Realizar análise exploratória dos dados com gráficos de preço, volume, retornos, médias móveis, correlações e identificação visual de tendência, sazonalidade e períodos atípicos;
- Implementar um modelo de persistência como *baseline* de comparação;
- Construir e treinar o modelo LSTM com 150 neurônios, avaliando seu desempenho frente ao *baseline* pelas métricas RMSE, MAE e MAPE;
- Desenvolver um protótipo web com Streamlit para visualização interativa das previsões e comunicação das limitações do modelo.

1.4. Opção do Projeto

Este projeto enquadra-se na **Opção ML/DL** (Machine Learning / Deep Learning), conforme as diretrizes da disciplina, empregando uma rede neural LSTM para solucionar um problema de regressão/predição em série temporal financeira, com dados capturados pelo grupo via API pública.

2. Fundamentação Teórica

2.1. Modelos Clássicos de Séries Temporais

A modelagem de séries temporais financeiras tem longa tradição acadêmica. O modelo ARIMA (*Auto-Regressive Integrated Moving Average*), introduzido por Box e Jenkins na década de 1970, foi por décadas o padrão de referência para previsão de séries univariadas [Box and Jenkins 1970]. O ARIMA combina autorregressão (AR), diferenciação para tornar a série estacionária (I) e médias móveis dos resíduos (MA). Suas principais limitações para aplicação em dados financeiros são: (i) exigência de estacionariedade, que requer transformações que podem comprometer a estrutura e interpretabilidade dos dados; e (ii) incapacidade de capturar relações não-lineares, frequentes em séries de preços de ativos [Nascimento et al. 2022].

2.2. Redes Neurais Recorrentes (RNN)

Redes neurais artificiais convencionais (*feedforward*) processam cada entrada de forma independente, sem memória de passos anteriores, tornando-as inadequadas para dados sequenciais. As Redes Neurais Recorrentes (RNN) introduzem conexões cíclicas que permitem a passagem de informação entre instantes de tempo consecutivos, habilitando o aprendizado de dependências temporais. O treinamento ocorre via retropropagação através do tempo (*Backpropagation Through Time* – BPTT). Contudo, em sequências longas, os gradientes tendem a decair exponencialmente nas camadas anteriores, problema conhecido como *vanishing gradient*, impedindo que a rede aprenda dependências de longo prazo.

2.3. LSTM (*Long Short-Term Memory*)

A arquitetura LSTM, proposta por [Hochreiter and Schmidhuber 1997], resolve o *vanishing gradient* mediante um mecanismo de portões (*gates*) e um componente chamado **estado da célula** (c_t), que mantém um caminho linear ao longo do tempo com operações de soma e multiplicação simples, preservando o fluxo de gradientes sem ativações não-lineares que causariam decaimento.

Cada célula LSTM recebe, a cada instante t : a entrada atual x_t , o estado oculto anterior h_{t-1} (memória de curto prazo) e o estado da célula anterior c_{t-1} (memória de longo prazo). Três portões controlam seletivamente o fluxo de informações:

- **Forget gate**: decide quais informações de c_{t-1} devem ser descartadas – $f_t = \sigma(W_f x_t + W_{hf} h_{t-1} + b_f)$;
- **Input gate**: decide quais novas informações serão armazenadas – $i_t = \sigma(W_i x_t + W_{hi} h_{t-1} + b_i)$;
- **Output gate**: decide quais informações do estado atual serão passadas como saída – $o_t = \sigma(W_o x_t + W_{ho} h_{t-1} + b_o)$.

O estado da célula é atualizado por $c_t = f_t \otimes c_{t-1} + i_t \otimes \tilde{c}_t$, onde $\tilde{c}_t = \tanh(W_c x_t + W_{hc} h_{t-1} + b_c)$. O estado oculto de saída é dado por $h_t = o_t \otimes \tanh(c_t)$, onde σ é a função sigmoide, $\tanh$ é a tangente hiperbólica e $\otimes$ é o produto elemento a elemento.

2.4. Média Móvel Exponencial (EMA)

A Média Móvel Exponencial (*Exponential Moving Average* – EMA) é um indicador técnico de tendência que pondera as observações históricas de forma exponencialmente

decrecente, atribuindo maior peso aos preços mais recentes. Diferentemente da Média Móvel Simples (SMA), que trata todas as observações da janela com pesos iguais, a EMA responde mais rapidamente a mudanças recentes no mercado [Zanotto and Hölbis 2026].

Dado um período n , o fator de suavização α é definido como:

$$\alpha = \frac{2}{n + 1} \quad (1)$$

O valor da EMA a cada instante t é calculado recursivamente por:

$$\text{EMA}_t = \alpha \cdot x_t + (1 - \alpha) \cdot \text{EMA}_{t-1} \quad (2)$$

onde x_t é o valor observado no instante t (preço de fechamento ajustado) e EMA_{t-1} é o valor da EMA no instante anterior. O valor inicial EMA_1 é tipicamente definido como x_1 .

Neste trabalho, adota-se o período de **60 dias** (EMA-60), seguindo a escolha metodológica de [Zanotto and Hölbis 2026]. Esse período captura tendências de médio prazo, aproximadamente três meses de pregões, equilibrando sensibilidade a novas informações com estabilidade suficiente para atenuar ruídos de curto prazo. A EMA-60 é calculada sobre o fechamento ajustado e adicionada como sétima *feature* de entrada do modelo, fornecendo uma representação explícita da tendência subjacente aos preços e melhorando a capacidade preditiva da LSTM.

2.5. Normalização por Z-score

A padronização por Z-score (*Z-score normalization* ou *standardization*) é uma técnica de pré-processamento que transforma cada variável de forma a ter média zero e desvio padrão unitário. A transformação é definida por:

$$z = \frac{x - \mu}{\sigma} \quad (3)$$

onde x é o valor original, μ é a média e σ é o desvio padrão da variável no conjunto de treinamento. A normalização é essencial em modelos de redes neurais, pois garante que variáveis com escalas muito distintas, como preços (na ordem de R\$ 20–40) e volume de negociações (na ordem de milhões), contribuam de forma equilibrada para o aprendizado, evitando que gradientes de maior magnitude dominem a otimização [Zanotto and Hölbis 2026].

Cada uma das seis variáveis de entrada (abertura, máxima, mínima, fechamento ajustado, volume e EMA-60) é normalizada individualmente, preservando suas características estatísticas específicas. De forma crítica, os parâmetros μ e σ são estimados **exclusivamente no conjunto de treinamento** e aplicados ao conjunto de teste sem recalibração, evitando *data leakage*, situação em que informações do futuro vazam para o treinamento do modelo e produzem avaliações artificialmente otimistas. Os escaladores são serializados via `joblib` para reutilização durante a inferência na aplicação Streamlit, onde as previsões produzidas em escala padronizada são revertidas à escala original em reais para interpretação direta.

2.6. Trabalhos Relacionados

A Tabela 1 apresenta os principais trabalhos relacionados identificados na revisão da literatura, com foco nos estudos voltados para ativos da B3.

Tabela 1. Trabalhos relacionados: previsão de preços de ações com LSTM e ML

Autores	Ativos	Modelo(s)	Principais resultados
Silveira (2021)	PETR4 (B3)	LSTM, Random Forest	LSTM eficaz na B3; RMSE de 1,72 para PETR4; escassez de estudos no mercado brasileiro.
Nascimento et al. (2022)	PETR4, ITUB4, BOVA11 (B3)	ARIMA, Prophet, LSTM	LSTM mais preciso para até 90 dias; ARIMA e Prophet superiores no curtíssimo prazo.
Bhandari et al. (2022)	S&P 500 (EUA)	LSTM (1 e 2+ camadas)	LSTM de camada única (150 neurônios) superou todas as arquiteturas multicamadas; $R = 0,9976$.
Mintarya et al. (2023)	Global (revisão)	Revisão sistemática	LSTM é o modelo mais adotado em finanças desde 2015; supera SVM e KNN na maioria dos estudos.
Zanotto & Hölbig (2026)	5 ações + 2 ETFs (B3)	LSTM (2 camadas, 500 neur.)	ITUB4 obteve melhor desempenho ($R^2 = 0,9917$, MAPE = 1,12%); PETR4 apresentou maior erro por volatilidade política.

Dentre os trabalhos analisados, destaca-se a convergência de dois achados metodológicos que orientam este projeto: (i) [Zanotto and Hölbig 2026] demonstrou que o ITUB4, como empresa privada com menor interferência governamental, apresenta preços mais previsíveis do que empresas estatais como PETR4 e BBAS3, justificando sua escolha como ativo principal; e (ii) [Bhandari et al. 2022] comprovou estatisticamente, via teste-t de Welch ($p = 7,08 \times 10^{-29}$), que um modelo LSTM de camada única com 150 neurônios supera arquiteturas multicamadas em todas as métricas avaliadas, motivando a escolha de uma arquitetura mais enxuta neste trabalho.

3. Metodologia e Resultados Esperados

3.1. Abordagem e Etapas

A metodologia é estruturada em quatro fases sequenciais, sendo descritas a seguir:

Fase 1 – Coleta e Análise Exploratória dos Dados: coleta automática via API *yfinance* do histórico de 5 anos do ativo ITUB4.SA (Open, High, Low, Close, Volume), cálculo da EMA-60 como variável auxiliar e geração de visualizações exploratórias: série histórica de preços, retornos diários, volume, sobreposição de médias móveis, mapa de calor de correlações e identificação visual de tendência, sazonalidade e períodos atípicos.

Fase 2 – Preparação dos Dados e Baseline: normalização via Z-score, divisão cronológica em treino e teste (80% / 20%), construção das janelas temporais de 50 dias e implementação do modelo de persistência como *baseline*.

Fase 3 – Modelagem e Treinamento da LSTM: construção da arquitetura, treinamento com *early stopping* e *ModelCheckpoint*, avaliação comparativa das métricas e geração do gráfico de preços reais versus previsões.

Fase 4 – Protótipo Web e Relatório Final: integração do modelo treinado ao Streamlit e redação das seções finais do artigo.

3.2. Dataset

Fonte: API *yfinance* (Yahoo Finance), de acesso público e sem necessidade de autenticação.

Ativo selecionado: ITUB4.SA (Itaú Unibanco S.A.) – escolhido por apresentar o melhor desempenho preditivo dentre os ativos analisados por [Zanotto and Hölbis 2026] ($R^2 = 0,9917$), além de menor influência de fatores políticos externos em comparação com empresas estatais.

Período: últimos 5 anos a partir da data de execução (dados diários), cobrindo aproximadamente 1.250 pregões. Este recorte abrange o regime macroeconômico mais recente, incluindo os ciclos de alta e queda da Selic pós-pandemia, tornando os padrões aprendidos mais representativos do comportamento atual do ativo do que um horizonte de 10 anos.

Variáveis coletadas: preço de abertura, máxima, mínima, **fechamento** (variável-alvo) e volume de negociações.

Variável derivada: Média Móvel Exponencial de 60 dias (EMA-60), calculada sobre o fechamento ajustado. A EMA atribui pesos maiores às observações mais recentes, sendo mais sensível a mudanças recentes no mercado do que a SMA (*Simple Moving Average*). O período de 60 dias captura tendências de médio prazo, equilibrando sensibilidade a novas informações com estabilidade suficiente para evitar ruídos de curto prazo [Zanotto and Hölbis 2026].

3.3. Análise Exploratória dos Dados (EDA)

Antes da modelagem, será realizada uma análise exploratória sistemática com o objetivo de compreender a estrutura da série histórica, identificar padrões relevantes e detectar anomalias ou períodos atípicos que possam afetar o treinamento. As seguintes visualizações e análises serão geradas:

- **Série histórica de preços e volume:** gráficos de linha do preço de fechamento e do volume diário ao longo dos 5 anos, permitindo identificar visualmente tendências de longo prazo e episódios de alta volatilidade;
- **Retornos diários:** cálculo e visualização dos retornos logarítmicos ($r_t = \ln(P_t/P_{t-1})$), revelando a distribuição dos ganhos e perdas diárias, assimetria e a presença de *outliers* em períodos de crise;
- **Médias móveis:** sobreposição das médias móveis simples de 20 e 50 dias (SMA-20 e SMA-50) e da EMA-60 sobre o gráfico de preços, evidenciando tendências de curto e médio prazo e sinais técnicos clássicos (cruzamento de médias);

- **Mapa de calor de correlações:** matriz de correlação de Pearson entre todas as variáveis (Open, High, Low, Close, Volume, EMA-60), identificando multicolinearidade e a relevância relativa de cada *feature*;
- **Identificação de períodos atípicos:** marcação visual de eventos de alta volatilidade no gráfico de preços (ex.: março de 2020 – início da pandemia; 2022 – ciclo de alta da Selic), contextualizando os limites do modelo para prever rupturas de padrão.

3.4. Pré-processamento dos Dados

Tratamento de dados ausentes: os preços ausentes por feriados ou falhas técnicas serão preenchidos com interpolação linear; registros de volume zerado serão preenchidos com o último valor disponível (*forward fill*).

Normalização (Z-score): cada variável será padronizada individualmente para média zero e desvio padrão unitário, conforme a transformação:

$$z = \frac{x - \mu}{\sigma} \quad (4)$$

Os parâmetros μ e σ serão estimados **exclusivamente no conjunto de treinamento** e aplicados ao conjunto de teste, evitando *data leakage*. Os escaladores serão serializados via `joblib` para uso posterior no Streamlit.

Divisão temporal: os dados serão divididos cronologicamente em 80% para treino e 20% para teste, sem embaralhamento, preservando a ordem temporal e simulando o cenário real de previsão. O *Early Stopping* e o *ModelCheckpoint* utilizam internamente uma fração do conjunto de treino como validação durante o ajuste dos pesos, sem comprometer o conjunto de teste.

Janelamento temporal: uma função de janelamento transformará o formato tabular em tensores tridimensionais [*amostras*, *passos_de_tempo*, *features*], exigidos como entrada pela LSTM. O *window size* de **50 dias** (aproximadamente 2 meses de pregões) será adotado com base em [Zanotto and Hölbis 2026] e em testes empíricos reportados na literatura.

3.5. Arquitetura do Modelo

A arquitetura LSTM foi definida com base no achado central de [Bhandari et al. 2022]: modelos de camada única superam consistentemente arquiteturas multicamadas em métricas de predição e oferecem menor tempo de treinamento com menor risco de *overfitting*. A Tabela 2 detalha a estrutura proposta.

Compilação: função de perda MSE (*Mean Squared Error*) e otimizador Adam (*Adaptive Moment Estimation*).

Callbacks: *Early Stopping* com paciência de 10 épocas sem melhora na perda de validação; *ModelCheckpoint* para salvar automaticamente os pesos do melhor modelo em arquivo `.h5`.

3.6. Modelo Baseline

O modelo de persistência (“*amanhã = hoje*”) será implementado como *baseline*: o preço previsto para o dia $t + 1$ é simplesmente o preço observado no dia t . Este modelo

Tabela 2. Arquitetura do modelo LSTM proposto

Camada	Configuração	Função
Input	Shape: (50, 6)	Recebe as sequências históricas de 50 dias com 6 <i>features</i> (Open, High, Low, Close, Volume, EMA-60)
LSTM	150 unidades, <code>return_sequences=True</code>	Processa a sequência e produz um único estado de saída
Dropout	Taxa = 20%	Regularização: desativa aleatoriamente unidades para reduzir <i>overfitting</i>
Dense	1 neurônio, ativação linear	Gera a previsão do preço de fechamento para o próximo dia

trivial serve como piso mínimo de comparação, a LSTM só será considerada válida se seus erros forem consistentemente menores do que os do *baseline* em todas as métricas.

3.7. Métricas de Avaliação

O desempenho dos modelos será mensurado pelas três métricas da Tabela 3, calculadas exclusivamente sobre o conjunto de teste. Todas as avaliações ocorrerão sobre os valores desnormalizados (revertidos ao domínio original em reais), permitindo interpretação direta dos erros e comparação com o *baseline* de persistência.

Tabela 3. Métricas de avaliação utilizadas

Métrica	Fórmula	Interpretação
RMSE	$\sqrt{\frac{1}{N} \sum (y_i - \hat{y}_i)^2}$	Erro na escala original (R\$); penaliza erros grandes
MAE	$\frac{1}{N} \sum y_i - \hat{y}_i $	Erro médio absoluto; menos sensível a <i>outliers</i>
MAPE	$\frac{1}{N} \sum \left \frac{y_i - \hat{y}_i}{y_i} \right \times 100$	Erro relativo percentual (%); permite comparação independente da escala de preços

3.8. Protótipo Web (Streamlit)

O modelo treinado será integrado em uma aplicação *web* desenvolvida com Streamlit, contendo: (i) gráfico interativo com preços reais versus previsões da LSTM no período de teste; (ii) painel de métricas (RMSE, MAE, MAPE); e (iii) seção obrigatória de **aviso legal e limitações**, com o texto: “*Esta ferramenta é um apoio analítico baseado em padrões históricos. O desempenho passado não garante resultados futuros. Não constitui recomendação de investimento.*” As limitações do modelo (incapacidade de capturar eventos geopolíticos, decisões governamentais e sentimento de mercado) serão explicitadas nesta seção.

3.9. Resultados Esperados

Baseando-se nos resultados de [Zanotto and Hölbisg 2026] para o ITUB4, que obteve MAPE de 1,12% com 10 anos de dados, espera-se que o modelo LSTM proposto alcance MAPE abaixo de 2% e supere o *baseline* de persistência em todas as métricas (RMSE, MAE e MAPE). A margem conservadora em relação à referência decorre do menor volume de dados históricos (5 anos). A entrega final compreende: (a) *notebook* Jupyter documentado com toda a *pipeline* de dados, EDA e treinamento; (b) aplicação Streamlit funcional; e (c) repositório público no GitHub com todos os artefatos.

4. Resultados Parciais

4.1. Aspectos Éticos do Uso da IA

O uso de modelos preditivos baseados em aprendizado de máquina em domínios financeiros levanta questões éticas relevantes que o grupo reconhece e incorpora explicitamente à solução:

Não-recomendação de investimentos: o modelo prevê preços com base em padrões históricos, sem considerar análise fundamentalista, informações privilegiadas ou o perfil de risco de cada investidor. Qualquer interpretação dos resultados como indicação de compra ou venda de ativos é responsabilidade exclusiva do usuário. O protótipo Streamlit exibirá este aviso em destaque.

Limitações da modelagem: a LSTM não consegue antecipar eventos externos não modelados: pandemias, mudanças abruptas de política monetária, intervenções governamentais em empresas estatais ou escândalos corporativos. [Zanotto and Hölbisg 2026] demonstrou empiricamente que esses fatores elevam significativamente o erro de predição, especialmente em empresas estatais como PETR4. A escolha do ITUB4 como ativo principal mitiga, mas não elimina este problema.

Transparência e reprodutibilidade: todo o código-fonte, dados utilizados e hiperparâmetros do modelo serão publicados em repositório público no GitHub, permitindo auditoria e reprodução independente dos resultados.

Viés de dados históricos: o modelo aprende padrões do passado, que podem não se repetir. Períodos de alta volatilidade (como crises financeiras ou choques de commodities) podem degradar significativamente o desempenho preditivo, limitação que será discutida na aplicação Streamlit.

4.2. Resultados Parciais Obtidos

Na data de entrega deste relatório, o grupo concluiu as seguintes atividades:

- **Revisão da literatura:** análise aprofundada de dois artigos científicos de referência ([Zanotto and Hölbisg 2026] e [Bhandari et al. 2022]), além de revisão de trabalhos relacionados publicados nos últimos cinco anos;
- **Definição metodológica:** escolha e justificativa do ativo (ITUB4), do período de coleta (5 anos), das variáveis predictoras (OHLCV + EMA-60), da janela temporal (50 dias), da divisão cronológica treino/teste (80%/20%), da arquitetura (LSTM 1 camada, 150 neurônios, Dropout 20%) e das métricas de avaliação (RMSE, MAE, MAPE);

- **Configuração do ambiente:** estrutura do repositório GitHub criada com organização de pastas para dados, notebooks e aplicação Streamlit; dependências Python definidas.

A implementação do código Python (coleta de dados, EDA, treinamento do modelo e interface Streamlit) constitui a próxima etapa, conforme o cronograma de quatro semanas estabelecido na metodologia.

4.3. Repositório GitHub

O código-fonte, os *notebooks* de análise exploratória e os artefatos gerados estão disponíveis no repositório público:

<https://github.com/LucasZanini096/Artificial-Intelligence-Project>

Referências

- Bhandari, H. N., Rimal, B., Pokhrel, N. R., Rimal, R., Dahal, K. R., and Khatri, R. K. C. (2022). Predicting stock market index using LSTM. *Machine Learning with Applications*, 9:100320.
- Box, G. E. P. and Jenkins, G. M. (1970). Time series analysis: Forecasting and control. *Holden-Day*.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.
- Mintarya, L. N., Halim, J. N., Angie, C., Abas, A. I., and Kurniawan, A. (2023). Machine learning approaches in stock market prediction: a systematic literature review. *Procedia Computer Science*, 216:96–102.
- Nascimento, A., Santos, F., and Ferreira, R. (2022). Análise comparativa de modelos de previsão de séries temporais financeiras: ARIMA, Prophet e LSTM. *Revista Brasileira de Computação Aplicada*, 14(3).
- Silveira, L. H. (2021). Previsão do preço de ações da Petrobras na bolsa de valores B3 utilizando LSTM e Random Forest. *Trabalho de Conclusão de Curso*.
- Zanotto, E. L. and Hölbis, C. A. (2026). Previsão de preços de ações e ETF na bolsa de valores B3 aplicando técnicas de machine learning. *Revista Sítio Novo*, 10:e1879.